

```
In [ ]: data<-read.csv("_6c939ae474f29a209ab5e3901864d38a_Data_Projects.csv", sep=";", dec=".")
```

```
In [ ]: summary(data)
```

AddressCount	CallsCount	ClicksCount	FirmsCount
Min. : 9	Min. : 20	Min. : 258	Min. : 14.0
1st Qu.: 81	1st Qu.: 346	1st Qu.: 2055	1st Qu.: 71.5
Median : 371	Median : 931	Median : 6921	Median : 185.0
Mean : 1048	Mean : 3649	Mean : 21826	Mean : 305.1
3rd Qu.: 1195	3rd Qu.: 2458	3rd Qu.: 30626	3rd Qu.: 402.5
Max. : 9552	Max. : 48497	Max. : 167155	Max. : 2379.0

GeoPart	MobilePart	UsersCount
0,0929166666666667: 1	0,09 : 1	Min. : 157
0,137857900318134 : 1	0,133974358974359: 1	1st Qu.: 1168
0,151738923296808 : 1	0,139612188365651: 1	Median : 2934
0,187886279357231 : 1	0,175525339925834: 1	Mean : 9753
0,193484698914116 : 1	0,200644166213028: 1	3rd Qu.: 13265
0,203374777975133 : 1	0,204181869211339: 1	Max. : 61127
(Other) : 73	(Other) : 73	

Distance	IsGeo
1004,78676794652: 1	Min. : 0.0000
1033,11276489631: 1	1st Qu.: 0.0000
1234,54344844949: 1	Median : 0.0000
1421,72399039962: 1	Mean : 0.3544
1423,37651183958: 1	3rd Qu.: 1.0000
1437,3055534143 : 1	Max. : 1.0000
(Other) : 73	

Рассчитайте основные статистики (меры центра и меры разброса) по распределениям всех переменных, имеющихся в файле данных.

Там, где имеются (Other) меры не могли быть рассчитаны.

1048.03797468354

2696381.13956508

In []: mean(data\$CallsCount)
var(data\$CallsCount)

3648.6835443038

66001088.5780591

In []: mean(data\$ClicksCount)
var(data\$ClicksCount)

21826.0126582278

1054622995.39727

In []: mean(data\$FirmsCount)
var(data\$FirmsCount)

305.088607594937

145963.799740344


In []: mean(data\$UsersCount)
var(data\$UsersCount)

9753.12658227848

193969566.086336


2. Выберите наиболее интересный для вас количественный признак и охарактеризуйте его распределение при помощи соответствующих описательных статистик и графиков:


ecdf(data\$CallsCount)




```
In [ ]: hist(data$CallsCount, breaks = "FD", freq = FALSE, col = "lightblue", xlab = "Время", ylab = "Концентрированность", density = 30, main = "Histogram of data$CallsCount") lines(density(data$CallsCount), col = "red", lwd = 2)
```


Histogram of data\$CallsCount



density.default(x = data\$CallsCount)


```
In [ ]: hist(data$CallsCount,freq = FALSE, col = "lightblue", xlab = "Время", ylab = "Концентрация")  
lines(density(data$CallsCount), col = "red", lwd = 2)
```

Histogram of data\$CallsCount




Вывод:

- 2.1. Какова форма распределения признака? - В выборке имеется смесь распределений
- 2.2. Можно ли говорить о том, что распределение признака согласуется с каким-либо теоретическим законом распределения? - Нет, на основании выборки нельзя судить об едином распределении данных. Большинство данных сгруппированы до значения 15 тыс. Данные до 5 тыс. могут классифицироваться как данные с псевдонармальным распределением и асимметрией.
- 2.3. Есть ли в данных «аномалии» / «выбросы»? - Да, в данных есть выбросы (на основании BoxPlot)
- 2.4. Какие меры центра и вариативности подходят для описания распределений лучше всего? Почему? - Ввиду того, что распределение имеет выбросы и не близко к нормальному, то для определения центра наиболее приемлемыми будут медиана и мода; для оценки вариативности - размах, межквартильный размах.
3. Сравните геозависимые и генезависимые сферы (экспертная разметка, переменная IsGeo) по выбранному для анализа признаку. Есть ли отличия? В чем они состоят? (для ответа на вопрос используйте статистические и графические инструменты).




```
In [ ]: hist(data$IsGeo, freq = FALSE, col = "lightblue", xlab = "Время", ylab = "Концентрация")
lines(density(data$IsGeo), col = "red", lwd = 2)
```

Histogram of data\$IsGeo




Microsoft Azure
Notebooks]: hist(data\$IsGeo, breaks = "FD", freq = FALSE, col = "#0072BD", My (https://docs.microsoft.com/en- (/boiarkin-
Preview (/help/preview) Projects/use/projects#) Highblue", xlab = "Время", ylab = "Концентраци- boiarkin-
lines(density(data\$IsGeo), col = "red", lwd = 2) ise")

Histogram of data\$IsGeo



In []: boxplot(data\$IsGeo)



Microsoft Azure
Notebooks
(/#)

Preview
(/help/preview)

My... (/boiarkin...
Projects ise/projects#)
https://docs.microsoft.com/en-us/azure/notebooks/

boiarkin...
ise



Вывод: переменная IsGeo является бинарной/номинальной переменной. Мерой среднего в таком случае будет выступать мода, мерой вариативности - отсутствует.